

THUYẾT MINH GIẢI PHÁP: AGENT AI KIỂM CHỨNG HAI LƯỢT ĐỒNG THUẬT

Đơn vị dự thi: thengbeo8686

Bảng

1. TỔNG QUAN GIẢI PHÁP

Đối với các mô hình ngôn ngữ lớn có kích thước nhỏ (kích thước $\leq 5B$), hai thách thức lớn nhất khi giải quyết bài toán trắc nghiệm phức tạp là:

1. T
kể nội

Giải pháp của chúng tôi xây dựng một Agent AI tự động kiểm chứng và đồng thuận, tích hợp công nghệ RAG tối ưu hóa để giải quyết triệt để hai vấn đề trên một cách ổn định, chính xác và hiệu quả nhất trên hạ tầng offline.

2. KIẾN TRÚC & LƯỒNG XỬ LÝ (PIPELINE FLOW)

Hệ thống hoạt động theo quy trình khép kín End-to-End gồm 6 bước chính:

[Dữ liệu Đầu Vào]

|

Chi tiết các bước kỹ thuật:

1. RAG & Pruning Context (Trích xuất tri thức động):

Hệ th
contai
ưu hó

3. CÁC ĐIỂM TỐI ƯU CÔNG NGHỆ ĐẶC BIỆT

GPU VRAM-Based Auto-Tuning (Tự động thích ứng phần cứng):

Hệ thống tích hợp bộ tự động phát hiện dung lượng bộ nhớ (VRAM) của GPU khi khởi động.

- Nế

Dynamic Model Path Resolution (Quét đường dẫn động):

Code tích hợp bộ nhận diện thư mục thông minh. Dù BTC mount mô hình Qwen vào bất kỳ tên thư mục con nào trong `/models/`, Agent vẫn tự tìm thấy và tải mô hình thành công, loại bỏ hoàn toàn rủi ro crash do sai tên đường dẫn.

Môi trường CUDA 12.8:

Docker Image được tối ưu hóa trên base image `nvidia/cuda:12.8.0-devel-ubuntu22.04` nhằm tương thích hoàn hảo và tối đa hiệu năng của dòng card Blackwell (RTX 5060Ti) trên máy chủ của BTC.

Offline 100% (Zero Internet):

Mô hình RAG embedding `BAAI/bge-m3` được tải trước và đóng gói trực tiếp vào Docker image lúc build. Hệ thống vận hành hoàn hảo không cần kết nối internet.

4. HƯỚNG DẪN VẬN HÀNH DÀNH CHO BTC

Lệnh chạy Docker Container vật lý:

BTC chỉ cần chạy lệnh tiêu chuẩn sau để mount file test và mô hình vật lý vào container:

```
docker run --gpus all \
```

-v /pa

Trong đó:

- Th