

THUYẾT MINH GIẢI PHÁP: AGENT AI KIỂM CHỨNG HAI LƯỢT ĐỒNG THUẬN (DOUBLE-RUN SHUFFLED RAG AGENT WITH AUTO-TUNING CONSENSUS)

Đơn vị dự thi: thengbeo8686

Bảng thi: Bảng C - Innovator (HackAlthon 2026)

1. TỔNG QUAN GIẢI PHÁP

Đối với các mô hình ngôn ngữ lớn có kích thước nhỏ (kích thước $\leq 5B$), hai thách thức lớn nhất khi giải quyết bài toán trắc nghiệm phức tạp là:

- Thiên kiến vị trí (Position Bias):** Mô hình có xu hướng ưu tiên chọn các đáp án nằm ở vị trí đầu tiên (A hoặc B) bất kể nội dung câu hỏi.
- Ảo giác thông tin & Giới hạn ngữ cảnh (Context Noise):** Tài liệu ngữ cảnh đi kèm quá dài và chứa nhiều thông tin nhiễu, làm loãng sự chú ý của mô hình.

Giải pháp của chúng tôi xây dựng một Agent AI tự động kiểm chứng và đồng thuận, tích hợp công nghệ RAG tối ưu hóa để giải quyết triệt để hai vấn đề trên một cách ổn định, chính xác và hiệu quả nhất trên hạ tầng offline.

2. KIẾN TRÚC & LƯỒNG XỬ LÝ (PIPELINE FLOW)

Hệ thống hoạt động theo quy trình khép kín End-to-End gồm 6 bước chính:

[Dữ liệu Đầu Vào]

Chi tiết các bước kỹ thuật:

1. RAG & Pruning Context (Trích xuất tri thức động):

Hệ thống đọc các đoạn thông tin đi kèm câu hỏi, sử dụng mô hình embedding **BGE-M3** (chạy offline hoàn

toàn trong container) để xếp hạng mức độ liên quan và chỉ giữ lại `top\_k` ngữ cảnh có độ tương quan cao nhất. Điều này giúp tối ưu hóa token đầu vào và loại bỏ nhiễu thông tin.

2. **Option Shuffling (Khử thiên kiến vị trí):**

Để loại bỏ Position Bias, hệ thống thực hiện đảo ngẫu nhiên thứ tự các đáp án lựa chọn (A, B, C, D...) trước khi đưa vào mô hình sinh câu trả lời.

3. **Double-Run Parallel Inference (Chạy hai lượt song song):**

GPU thực hiện sinh câu trả lời cho cả 2 phiên bản (Lượt gốc và Lượt đảo đáp án) trong cùng một tiến trình xử lý song song để tiết kiệm thời gian tối đa.

4. **Voting Consensus (Đối chiếu đồng thuận):**

Ánh xạ kết quả của Lượt đảo đáp án về chữ cái lựa chọn ban đầu rồi đối chiếu với Lượt gốc.

- Nếu trùng khớp: Mô hình tự tin với đáp án $\rightarrow$ Xuất kết quả.

- Nếu mâu thuẫn: Câu hỏi được đưa vào **Pass 2**.

5. **Pass 2 & Tie-breaking (Giải quyết xung đột):**

Các câu hỏi mâu thuẫn được chạy lại một lần nữa (2 lượt). Hệ thống tiến hành bầu chọn đa số (Majority Voting) từ 4 kết quả thu được. Nếu xảy ra hòa phiếu, hệ thống áp dụng cơ chế ưu tiên đáp án của lượt chạy gốc ổn định nhất để phân xử (Tie-breaker).

6. **Inference Time Logging (Đo lường thời gian thực tế):**

Hệ thống đo chính xác thời gian truy xuất embedding và thời gian chạy GPU thực tế chia đều trên từng mẫu dữ liệu để ghi nhận vào cột `time` của file báo cáo.

3. CÁC ĐIỀU TỐI ƯU CÔNG NGHỆ ĐẶC BIỆT

- GPU VRAM-Based Auto-Tuning (Tự động thích ứng phần cứng):

Hệ th

4. HƯỚNG DẪN VẬN HÀNH DÀNH CHO BTC

Lệnh chạy Docker Container vật lý:

BTC chỉ cần chạy lệnh tiêu chuẩn sau để mount file test và mô hình vật lý vào container:

```
docker run --gpus all \
```

Trong đó:

• Thu